

# Procesamiento de Imágenes para la Detección del Acné

Gorriti, Ignacio Ezequiel - Vazquez Arispe, Martin

[igorriti@alumnos.exa.unicen.edu.ar](mailto:igorriti@alumnos.exa.unicen.edu.ar) - [martin.vazquez.arispe@gmail.com](mailto:martin.vazquez.arispe@gmail.com)

Facultad de Cs. Exactas

Universidad Nacional del Centro de la Provincia de Buenos Aires

Cátedra: Procesamiento digital de imágenes I

Docente: Dr. José María Massa

## ÍNDICE

ÍNDICE	1
RESUMEN	2
DESARROLLO Y ANÁLISIS	3
ETAPAS DEL PROCESAMIENTO DE IMÁGENES	3
CAPTURA	3
ESTABLECIMIENTO DE LA ZONA DE DETECCIÓN	4
PREPROCESAMIENTO	5
DETECTOR DE BORDES CANNY	5
SEGMENTACIÓN	6
MEDICIÓN DE CARACTERÍSTICAS	6
CLASIFICACIÓN	6
POSTPROCESAMIENTO	7
ANÁLISIS DE RESULTADOS	8
OTROS TRABAJOS	10
ACNEDET	10
ACNE DETECTION AND SEVERITY EVALUATION WITH INTERPRETABLE CONVOLUTIONAL NEURAL MODELS	11
CONCLUSIÓN	13
REFERENCIAS	14

# RESUMEN

El acné es una condición dermatológica común que afecta a millones de personas en todo el mundo, causando no sólo problemas estéticos sino también impactos emocionales significativos. La detección y diagnóstico tempranos son cruciales para su tratamiento eficaz, lo que ha llevado a la búsqueda de métodos automatizados y precisos para identificar esta condición en imágenes faciales.

En este contexto, el procesamiento de imágenes ha emergido como una herramienta poderosa para el análisis dermatológico. Utilizando técnicas avanzadas de visión por computadora, es posible desarrollar sistemas que detecten automáticamente el acné, proporcionando una herramienta valiosa tanto para profesionales de la salud como para usuarios individuales.

Este trabajo se centra en el desarrollo de un sistema de detección de acné empleando Python y la biblioteca OpenCV. Python, conocido por su versatilidad y simplicidad, junto con OpenCV, una biblioteca ampliamente utilizada para procesamiento de imágenes y visión por computadora, ofrecen un entorno ideal para el desarrollo de soluciones innovadoras en el campo de la dermatología. A través de técnicas de preprocesamiento de imágenes, segmentación, medición de características y clasificación, se pretende crear un modelo eficiente y preciso capaz de identificar lesiones de acné en diversas imágenes faciales.

La implementación de este sistema no solo facilitará la detección automática de acné, sino que también allanará el camino para futuros desarrollos en aplicaciones dermatológicas automatizadas, mejorando así la accesibilidad y precisión del diagnóstico de esta afección común.

# DESARROLLO Y ANÁLISIS

En esta sección, se detallan los métodos y procedimientos implementados para la detección de acné utilizando Python y OpenCV, con un enfoque específico en la selección manual de la zona de interés por parte del usuario. Se describen los pasos del algoritmo aplicado a esta región seleccionada, desde el preprocesamiento de las imágenes hasta la segmentación y clasificación de las lesiones de acné. Además, se explica el uso de un dataset preexistente para entrenar y evaluar el modelo, garantizando así la robustez y precisión del sistema desarrollado.

## ETAPAS DEL PROCESAMIENTO DE IMÁGENES

El procesamiento de imágenes es una técnica fundamental en el campo de la visión por computadora, que permite analizar y manipular imágenes digitales para obtener información útil. Este proceso involucra varias etapas clave: la captura de las imágenes, seguida por el preprocesamiento para mejorar su calidad, la segmentación para dividir la imagen en regiones de interés, la medición de características para extraer atributos relevantes, y finalmente, la clasificación para identificar y categorizar las diferentes partes de la imagen. Cada una de estas etapas es crucial para desarrollar sistemas efectivos de análisis y reconocimiento de imágenes.

### CAPTURA

La captura de imágenes es el proceso inicial en el procesamiento de imágenes digitales, donde se adquieren fotografías o imágenes mediante dispositivos como cámaras, escáneres o sensores. Durante este proceso, se registran las características visuales del objeto o escena que se está capturando, convirtiéndolas en datos digitales que pueden ser procesados por una computadora. La calidad y la precisión de la captura son fundamentales, ya que afectan directamente a la eficacia de las etapas subsiguientes del procesamiento de imágenes. La captura puede variar en complejidad dependiendo del dispositivo utilizado y del entorno en el que se realiza, pero su objetivo principal es obtener una representación fiel y detallada de la escena o del objeto de interés.

En este proyecto, no se realizó la captura directa de imágenes, sino que se optó por utilizar un dataset preexistente. Este enfoque nos permitió trabajar con una colección diversa y previamente anotada de imágenes faciales, lo cual fue fundamental para entrenar y evaluar el algoritmo de detección de acné. El uso de un dataset ya existente no solo ahorra tiempo y recursos, sino que también garantiza la consistencia y calidad de las imágenes, ya que provienen de fuentes reconocidas y han sido preparadas específicamente para estudios dermatológicos. Esta decisión nos permitió concentrar

nuestros esfuerzos en el desarrollo y optimización del algoritmo, asegurando al mismo tiempo una base sólida de datos para el análisis.



Figura 1. Ejemplos del dataset

El dataset completo se puede acceder a través del siguiente [link](#).

## ESTABLECIMIENTO DE LA ZONA DE DETECCIÓN

Para determinar la zona en la que se va a detectar el acné, se permite al usuario interactuar directamente con la imagen. El usuario puede marcar la región deseada utilizando el mouse, lo que facilita la especificación precisa del área de interés. Al presentar la imagen en la interfaz, el usuario simplemente hace clic y arrastra el mouse para dibujar un rectángulo o una forma que delimite la zona donde se realizará la detección de acné. Este enfoque interactivo garantiza que el análisis se centre

únicamente en la región seleccionada, mejorando la precisión y relevancia de los resultados obtenidos.

## PREPROCESAMIENTO

En esta etapa se mejora la calidad de las imágenes y las prepara para análisis posteriores. Esto incluye reducir el ruido, ajustar el brillo y contraste, y corregir distorsiones. Al limpiar y mejorar las imágenes, se asegura que los algoritmos de análisis trabajen con datos más precisos, mejorando así el rendimiento de los sistemas de visión por computadora.

En este trabajo se convierte la imagen original a escala de grises. Luego, se aplica el detector de bordes de Canny para resaltar los bordes significativos en la imagen. Finalmente, se realiza una dilatación de estos bordes, facilitando la posterior segmentación y detección de contornos.




Figura 2. Imagen a la salida del preprocesamiento

## DETECTOR DE BORDES CANNY

El detector de bordes de Canny es un algoritmo popular en procesamiento de imágenes que identifica los bordes de los objetos en una imagen. El proceso incluye la reducción de ruido con un filtro Gaussiano, el cálculo de gradientes para detectar cambios de intensidad, la supresión de píxeles no máximos para afinar los bordes, y la aplicación de umbrales para distinguir bordes fuertes y débiles. Finalmente, se conectan los píxeles débiles a los fuertes, garantizando bordes nítidos y precisos.

## SEGMENTACIÓN

Aquí se divide una imagen en regiones significativas para facilitar su análisis. Identifica y aísla objetos de interés del fondo utilizando métodos como la umbralización y la detección de bordes. Es esencial para aplicaciones como el reconocimiento de objetos y la detección de rostros, mejorando la precisión y eficiencia del análisis.

La segmentación se lleva a cabo mediante la detección de contornos en la imagen preprocesada. Esto se realiza con la función *findContours* de openCV, que encuentra y almacena los contornos de los objetos en la imagen. Los contornos detectados representan posibles áreas de interés donde podría estar presente el acné.

## MEDICIÓN DE CARACTERÍSTICAS

La medición de características en el procesamiento de imágenes extrae información cuantitativa de las regiones segmentadas, como formas, tamaños, texturas y colores. Utiliza técnicas como el análisis de contornos e histogramas de intensidad. Esta etapa es esencial para la identificación de patrones, el reconocimiento de objetos y el análisis, mejorando la precisión de los algoritmos.

Después de detectar los contornos, se mide el tamaño y el color de cada región de interés. Para cada contorno, se calcula un rectángulo delimitador mínimo con la función de openCV *boundingRect*. Se extrae la región de interés (ROI) correspondiente y se convierte a espacio de color HSV para obtener el color promedio. Además, se calcula el círculo mínimo que encierra cada contorno, obteniendo así el centro y el radio del contorno.

## CLASIFICACIÓN

En esta etapa se asignan etiquetas a objetos o regiones basándose en características extraídas. Puede utilizar tanto algoritmos de aprendizaje automático como métodos tradicionales basados en reglas. Es crucial para aplicaciones como la detección de enfermedades y la identificación de objetos, proporcionando resultados precisos y fiables.

La clasificación se basa en reglas predefinidas. Se considera que un contorno representa una región con acné si el radio del círculo mínimo está entre 3 y 20 píxeles,

y si el color promedio de la región está dentro del rango específico de colores rojos. Para realizar esta comprobación de color se utiliza el siguiente criterio:

- Hue: Debe tener un valor entre 0 y 20, capturando tonalidades que van desde rojos hasta magentas.
- Saturation: Debe ser al menos 50 pero no superior a 255, lo que indica una saturación moderada a alta.
- Value: Debe ser al menos 50 pero idealmente menor a 220 para excluir los blancos.

Si ambas condiciones se cumplen, se dibuja un rectángulo verde alrededor de la región.

## POSTPROCESAMIENTO

El postprocesamiento en el procesamiento de imágenes mejora y refina los resultados tras la clasificación o análisis inicial. Incluye técnicas para eliminar errores y mejorar la visualización final, siendo esencial para optimizar la calidad y claridad de la información visual en aplicaciones como la detección de objetos y la mejora de imágenes médicas.

En el post procesamiento se realiza el siguiente procedimiento. Primero, se crea una máscara binaria para identificar las regiones detectadas como acné, convirtiendo los píxeles azules a blancos y ajustando la máscara. Luego, la máscara se aplica a la imagen original para combinar las áreas detectadas con la imagen fuente, produciendo una visualización final que muestra las áreas de acné destacadas de manera clara y precisa.




Figura 3. Salida del algoritmo

## ANÁLISIS DE RESULTADOS

Esta sección se enfoca en la evaluación detallada del sistema, a partir de una serie de pruebas realizadas con 39 imágenes. Este análisis tiene como objetivo principal determinar la precisión y la robustez del algoritmo utilizado. Para ello, se examinan múltiples métricas de rendimiento, incluyendo la tasa de verdaderos positivos, falsos negativos y falsos positivos. Además, se analiza la consistencia del sistema al identificar distintos tipos de lesiones acnéicas bajo diversas condiciones de iluminación y resolución de imagen. Para una mejor interpretación de los resultados se emplearon además 3 métricas fundamentales: precisión, sensibilidad y f1-score.

En primer lugar, se inició recolectando la cantidad total de verdaderos positivos (VP), falsos positivos (FP) y falsos negativos (FN). Para luego, obtener la precisión y la sensibilidad y finalmente el f1-score. A continuación, se presentan los resultados en las siguientes tablas:

Tabla de confusión de valores:

	Predicción Positiva (P)	Predicción Negativa (N)
Verdadero (V)	90	No obtenida
Falso (F)	59	26

Tabla de métricas:

Métrica	Descripción	Ecuación	Resultado
Precisión	Proporción de predicciones positivas correctas sobre el total de predicciones positivas.	$\frac{VP}{VP + FP}$	0.604
Sensibilidad	Proporción de casos positivos correctamente identificados sobre el total de casos positivos reales.	$\frac{VP}{VP + FN}$	0.775
F1 - Score	Media armónica entre precisión y sensibilidad, proporcionando una medida equilibrada del rendimiento del modelo.	$2 \times \frac{\text{precisión} \times \text{sensibilidad}}{\text{precisión} + \text{sensibilidad}}$	0.6792

Los resultados mostrados en la tabla de confusión y métricas indican el rendimiento de un modelo de detección de acné. La precisión del modelo es de 0.604, lo que significa que aproximadamente el 60.4% de las predicciones positivas son correctas. La



sensibilidad es de 0.775, indicando que el 77.5% de los casos positivos reales son identificados correctamente por el modelo. El F1-Score, una medida armonizada entre precisión y sensibilidad, es de 0.6792, lo que sugiere un balance moderado entre ambas métricas. Aunque la sensibilidad es aceptable, la precisión relativamente baja y el F1-Score indican que el modelo tiene margen para mejorar en términos de reducir los falsos positivos.

## OTROS TRABAJOS

En el vasto campo del procesamiento de imágenes, que abarca desde la medicina hasta la robótica, se explorará cómo se han enfrentado problemas similares en otros trabajos. Esta mención brindará una perspectiva amplia sobre las estrategias utilizadas en el análisis visual y detección de acné.

### ACNEDET

El trabajo se centra en el desarrollo de un sistema de inteligencia artificial llamado AcneDet que utiliza aprendizaje profundo y aprendizaje automático para analizar automáticamente imágenes faciales de smartphones con el fin de detectar objetos de lesiones de acné y clasificar la gravedad del acné según la escala IGA. Para lograr este resultado, se llevaron a cabo las siguientes acciones:

1. Recopilación y Etiquetado de Datos:
  - a. Se recopilaron 1572 imágenes de smartphones iOS y Android de una base de datos de una aplicación móvil llamada Skin Detective.
  - b. Cuatro dermatólogos etiquetaron las imágenes, marcando los tipos de lesiones de acné (puntos negros/granos blancos, pápulas/pústulas, nódulos/quistes y cicatrices de acné) y clasificando la gravedad del acné según la escala IGA.
2. Desarrollo del Sistema AcneDet:
  - a. Se desarrolló un sistema de inteligencia artificial que consta de dos modelos: uno para la detección de objetos de lesiones de acné utilizando aprendizaje profundo basado en Faster R-CNN, y otro para la clasificación de la gravedad del acné basado en aprendizaje automático con LightGBM.
3. Entrenamiento y Evaluación de los Modelos:
  - a. Se dividió el conjunto de datos en un conjunto de entrenamiento y un conjunto de prueba en una proporción de 70:30.
  - b. Se entrenaron los modelos en paralelo en los datos de entrenamiento hasta la convergencia.
  - c. Se evaluó el rendimiento de los modelos utilizando métricas como la Precisión Promedio (AP) para la detección de objetos de acné y el Área bajo la Curva ROC (AUC) para la clasificación de la gravedad del acné.
4. Resultados:
  - a. El modelo de detección de objetos de acné logró un AP de 0.54 y el modelo de clasificación de gravedad del acné alcanzó una precisión del 85%.

En conclusión, este estudio presenta un enfoque innovador que combina tecnología de smartphones e inteligencia artificial para mejorar la detección y clasificación del acné,

lo que podría tener implicaciones significativas en la atención dermatológica y el acceso a la atención médica.

## ACNE DETECTION AND SEVERITY EVALUATION WITH INTERPRETABLE CONVOLUTIONAL NEURAL MODELS

El acné vulgar es una de las afecciones cutáneas más prevalentes que afecta tanto a la condición fisiológica como a la salud mental de los pacientes. El diagnóstico temprano y el monitoreo continuo y preciso pueden ayudar a controlar y aliviar el malestar que causa el acné. En este contexto, el artículo se centra en el desarrollo y la comparación de modelos de aprendizaje profundo para localizar lesiones de acné en imágenes faciales y evaluar la severidad del acné utilizando criterios médicos.

A diferencia de la mayoría de la literatura existente sobre el análisis del acné facial, los modelos considerados en este estudio son modelos de detección de objetos con redes neuronales convolucionales (CNN) como columna vertebral, lo que proporciona una mayor interpretabilidad y resultados más confiables en la detección de acné y evaluación de la severidad del acné facial. Los experimentos realizados con datos reales validaron la efectividad de estos modelos, alcanzando una precisión media (mAP) de 0.536 en un conjunto de datos de código abierto y un error correspondiente en el conteo de lesiones de acné tan bajo como  $0.43 \pm 6.65$ .

El estudio se basa en el uso de imágenes tomadas por smartphones u otras cámaras portátiles, que son las más accesibles y convenientes para el monitoreo fuera del hospital. El artículo menciona trabajos previos, como los realizados por SkinVision, que han utilizado smartphones para analizar condiciones de la piel, y estudios de Google Health sobre sistemas de aprendizaje profundo para la detección de una amplia gama de enfermedades de la piel.

La investigación destaca la importancia de la autoevaluación continua del acné, que incluye el autodiagnóstico y la evaluación del efecto del tratamiento o la terapia proporcionada por los dermatólogos. Se hace referencia a estudios previos que establecen relaciones estadísticas entre la severidad del acné y el número de lesiones de acné, proporcionando reglas fáciles de usar para estimar la severidad del acné a partir del conteo de lesiones.

El artículo presenta un marco de trabajo que utiliza modelos de detección de objetos de última generación para analizar el acné facial. Estos modelos de detección de objetos tienen la ventaja de una alta interpretabilidad, a diferencia de los métodos "end-to-end" que simplemente producen el número de lesiones de acné o el nivel de severidad del

acné. La investigación también destaca la importancia de la eficiencia temporal de los métodos de detección de objetos, especialmente para aquellos con una columna vertebral pesada como ResNet-101.

El conjunto de datos utilizado para desarrollar y validar los modelos es el ACNE04, que contiene 1457 imágenes con anotaciones de cuadros delimitadores y el número de lesiones y severidad para cada imagen. Sin embargo, el conjunto de datos fue limpiado para eliminar imágenes de baja calidad y ajustar los cuadros delimitadores para una localización más precisa de las lesiones.

Los modelos de detección de objetos seleccionados incluyen SSD con MobileNet v1, Yolov4, y Faster R-CNN con ResNet como columna vertebral. Los experimentos realizados con estos modelos mostraron que Yolov4 y Faster R-CNN con ResNet-101 lograron los mejores resultados en términos de precisión media. Además, los modelos desarrollados se implementaron como un servicio accesible a través de una applet de WeChat, proporcionando monitoreo continuo fuera del hospital para los pacientes y ayudando a los dermatólogos a seguir el progreso de la enfermedad y evaluar la efectividad del tratamiento.

En resumen, el artículo demuestra que los modelos de detección de objetos con CNN pueden ser una herramienta eficaz para la detección y evaluación de la severidad del acné facial, ofreciendo una solución interpretable y precisa que puede ser utilizada tanto por pacientes como por dermatólogos.

# CONCLUSIÓN

El procesamiento de imágenes en la detección de acné ha demostrado ser una herramienta valiosa en dermatología, proporcionando un enfoque preciso y no invasivo para evaluar esta afección cutánea común. Al integrar técnicas tradicionales, como la detección de bordes, se logró resultados prometedores en la identificación de lesiones acneicas. A pesar de estos avances, persisten desafíos como la variabilidad en la presentación del acné en diferentes tipos de piel y condiciones de iluminación.

Para mejorar la aplicabilidad clínica de estos métodos, es crucial abordar estas variabilidades y fortalecer la robustez de los modelos mediante una mayor diversificación de conjuntos de datos y el desarrollo de técnicas más avanzadas. Con un enfoque continuo en la innovación y la colaboración interdisciplinaria entre dermatólogos, expertos en visión por computadora y probablemente científicos del aprendizaje automático, se puede avanzar hacia una detección más temprana y precisa del acné, mejorando así la calidad de vida de los pacientes afectados.

# REFERENCIAS

En este apartado se enumeran las referencias utilizadas en el desarrollo del proyecto, abarcando documentación de tecnologías utilizadas, artículos mencionados, documentación sobre técnicas estadísticas, entre otras menciones.

1. OpenCV. (n.d.). OpenCV documentation. Retrieved May 29, 2024, from <https://docs.opencv.org/4.x/>
2. Nguyen, Q. T. H., Nguyen, H. T., Nguyen, H. T., Nguyen, A. T., Tran, M. T.-T., Nguyen, H. T., ... & Ishii, T. (2022). Automatic Acne Object Detection and Acne Severity Grading Using Smartphone Images and Artificial Intelligence. *Diagnostics*, 12(10), 1879. <https://www.mdpi.com/2075-4418/12/8/1879>
3. Vázquez, M., & Gorriti, I. E. (2024). Acne detector [Repositorio de GitHub]. GitHub. [https://github.com/MartinVazquez1982/acne\\_detector](https://github.com/MartinVazquez1982/acne_detector)
4. Kerneler. (n.d.). Acne grading [Código y datos]. Kaggle. <https://www.kaggle.com/code/kerneler/starter-acne-grading-1f837b99-2/inpu>  
[ut](https://www.kaggle.com/code/kerneler/starter-acne-grading-1f837b99-2/inpu)
5. Liu, X., Luo, W., Zhang, J., Zheng, J., & Zhang, Y. (2022). *Acne detection and severity evaluation with interpretable convolutional neural network models*. ResearchGate. [https://www.researchgate.net/publication/358300244\\_Acne\\_detection\\_and\\_severity\\_evaluation\\_with\\_interpretable\\_convolutional\\_neural\\_network\\_mod](https://www.researchgate.net/publication/358300244_Acne_detection_and_severity_evaluation_with_interpretable_convolutional_neural_network_models)  
[els](https://www.researchgate.net/publication/358300244_Acne_detection_and_severity_evaluation_with_interpretable_convolutional_neural_network_models)